

# 基于粒子群算法和广义回归神经网络的岩爆预测

贾义鹏, 吕庆, 尚岳全

(浙江大学 建筑工程学院, 浙江 杭州 310058)

**摘要:** 岩爆是岩石深部开挖中一种常见的工程地质灾害。为评价岩爆发生的可能性, 提出一种基于粒子群算法和广义回归神经网络模型(PSO-GRNN 模型)的岩爆预测方法。该方法利用已有岩爆数据, 通过神经网络技术建立回归模型, 采用粒子群算法对模型参数进行优化, 减少人为因素对神经网络设计的影响。据此方法, 在能量理论的基础上, 选取洞壁围岩最大切向应力、岩石单轴抗压强度、抗拉强度和弹性能量指数作为主要影响因素, 利用国内外 26 组已有工程数据建立岩爆预测的 PSO-GRNN 模型。通过对苍岭隧道和冬瓜山铜矿岩爆预测的工程实例分析验证该方法的可行性和适用性。所提方法可为类似工程的岩爆预测提供参考。

**关键词:** 岩石力学; 岩爆; 岩石地下开挖; 粒子群算法; 广义回归神经网络

**中图分类号:** TU 45

**文献标识码:** A

**文章编号:** 1000-6915(2013)02-0343-06

## ROCKBURST PREDICTION USING PARTICLE SWARM OPTIMIZATION ALGORITHM AND GENERAL REGRESSION NEURAL NETWORK

JIA Yipeng, LU Qing, SHANG Yuequan

(College of Civil Engineering and Architecture, Zhejiang University, Hangzhou, Zhejiang 310058, China)

**Abstract:** Rockburst is a common engineering geological disaster in deep rock excavations. To evaluate the possibility of rockburst, a rockburst prediction method using the particle swarm optimization(PSO) algorithm and the general regression neural network(GRNN) model is proposed. This approach employs the technology of neural network to build up a regression model based on existing rockburst database, and takes advantage of PSO algorithm to optimize the parameters of the network which is believed to reduce the adverse influence of man-induced factors in model construction. Then, four major influence factors, including the maximum induced tangential stress on the boundaries of tunnels or caverns, the uniaxial compressive strength and the uniaxial tensile strength of the rock, and also the elastic energy index of the rock, are selected as the inputs for establishing the PSO-GRNN model based on the energy theory and the data obtained from 26 practical cases. The generated PSO-GRNN model is finally applied to predict the rockburst for the Cangling tunnel and Dongguashan copper mine, in which the feasibility and applicability of the proposed approach are illustrated. The methodology presented in the paper provides a reference for some similar engineering involving rockburst.

**Key words:** rock mechanics; rockburst; underground rock excavation; particle swarm optimization algorithm; general regression neural network

## 1 引言

岩爆是高地应力环境下岩石地下开挖工程中

一种常见的工程地质灾害, 是指岩体中聚积的弹性应变能因洞室开挖而释放, 导致岩体产生迸裂、弹射等脆性破坏现象。岩爆严重威胁地下工程的施工安全, 已造成了大量的人员伤亡和设备损毁。随着

**收稿日期:** 2012-05-14; **修回日期:** 2012-12-24

**基金项目:** 浙江省重大科技专项和优先主题资助项目(2010C13029); 国家自然科学基金资助项目(41202216)

**作者简介:** 贾义鹏(1981-), 男, 2009年毕业于西安建筑科技大学岩土工程专业, 现为博士研究生, 主要从事地下工程灾害防治方面的研究工作。E-mail: 870239264@qq.com。通讯作者: 吕庆(1978-), 男, 现任副教授。E-mail: lvqing@zju.edu.cn

我国水利、交通和采矿事业的快速发展,高地应力环境中的深部岩体开挖越来越多,岩爆的防控也越来越重要。

岩爆预测是岩爆灾害预防的基础,国内外学者对此开展了大量相关研究工作<sup>[1-2]</sup>。模糊数学<sup>[3]</sup>、灰色理论<sup>[4]</sup>、人工神经网络<sup>[5]</sup>、距离判别<sup>[6]</sup>、支持向量机<sup>[7]</sup>、功效系数法<sup>[8]</sup>、数据挖掘<sup>[9]</sup>等数学模型和智能算法被广泛地应用于岩爆预测研究,并取得了一定的成果。但上述预测方法普遍存在设计参数难以确定的缺点,其预测结果受人为主观因素影响较大,适用性不好,不能满足工程需要,因此有必要继续深入开展岩爆预测研究工作,探寻准确可靠、且在经济和技术上可行的岩爆预测方法。

智能岩石力学理论提出将人工智能方法与岩石力学交叉、融合,从岩体问题的实际出发,全面、系统地研究岩石力学问题。基于该思想,本文引入粒子群算法(particle swarm optimization, PSO)和广义回归神经网络模型(general regression neural network, GRNN)用于岩爆预测分析。首先针对岩爆这一物理现象,以能量理论为基础,从各种相关因素中筛选出对岩爆起主要影响的主控因子,然后结合粒子群算法和广义回归神经网络建立了一种新的岩爆预测方法。该方法通过 PSO 算法对 GRNN 模型参数进行优化,解决了 GRNN 拓扑结构难以确定的问题,同时保留了 GRNN 非线性映射能力强、容错性和鲁棒性高的特点,具有较高的预测精度和稳定性,并且编码简单、易于实现,建模所需参数也易于测取,有利于工程上应用推广。

本文以国内外 26 组工程实例数据为学习样本建立了 PSO-GRNN 岩爆预测模型,确定了岩爆烈度与岩体强度、洞壁围岩应力以及弹性能量指数等控制变量之间的非线性映射关系,通过对苍岭隧道和冬瓜山铜矿的岩爆实例预测验证了本文方法的准确性和适用性。

## 2 基于粒子群优化算法的广义回归神经网络模型(PSO-GRNN 模型)

广义回归神经网络是一种基于非线性回归理论的神经网络模型<sup>[10]</sup>,在数据拟合和学习速度方面较传统 BP 网络有优势,特别是在训练样本较少时能取得较好的回归预测效果。在岩土工程领域,GRNN 模型已在加筋土支挡结构高度预测<sup>[11]</sup>、土性曲线智

能模型构建<sup>[12]</sup>、地基土液化分析<sup>[13]</sup>、隧道围岩位移反演<sup>[14]</sup>等研究中获得了成功应用。

### 2.1 GRNN 模型

若自变量  $\mathbf{x}$  及其函数  $y$  均为随机变量,其联合概率密度函数记为  $f(\mathbf{x}, y)$ 。将  $\mathbf{x}$  的观测值记为  $\mathbf{X}$ ,函数  $y$  基于  $\mathbf{X}$  的值为  $Y$ ,其数学期望  $\hat{Y}$  为

$$\hat{Y} = E(y | \mathbf{X}) = \frac{\int_{-\infty}^{\infty} y f(\mathbf{X}, y) dy}{\int_{-\infty}^{\infty} f(\mathbf{X}, y) dy} \quad (1)$$

假定  $f(\mathbf{x}, y)$  服从正态分布,则有

$$\hat{f}(\mathbf{X}, Y) = \frac{1}{n(2\pi)^{(d+1)/2} \sigma^{(d+1)}} \cdot \sum_{i=1}^n \left\{ \exp \left[ -\frac{(\mathbf{X} - \mathbf{X}_i)^T (\mathbf{X} - \mathbf{X}_i)}{2\sigma^2} \right] \cdot \exp \left[ -\frac{(Y - Y_i)^2}{2\sigma^2} \right] \right\} \quad (2)$$

式中:  $n$  为学习样本数目,  $d$  为随机向量  $\mathbf{x}$  的维数,  $\sigma$  为光滑因子。

用  $\hat{f}(\mathbf{X}, Y)$  代替  $f(\mathbf{X}, y)$  并代入式(1),整理可得

$$\hat{Y} = \frac{\sum_{i=1}^n Y_i \exp \left[ -\frac{(\mathbf{X} - \mathbf{X}_i)^T (\mathbf{X} - \mathbf{X}_i)}{2\sigma^2} \right]}{\sum_{i=1}^n \exp \left[ -\frac{(\mathbf{X} - \mathbf{X}_i)^T (\mathbf{X} - \mathbf{X}_i)}{2\sigma^2} \right]} \quad (3)$$

若令

$$P_i = \exp \left[ -\frac{(\mathbf{X} - \mathbf{X}_i)^T (\mathbf{X} - \mathbf{X}_i)}{2\sigma^2} \right] \quad (4)$$

$$S_N = \sum_{i=1}^n Y_i P_i \quad (5)$$

$$S_D = \sum_{i=1}^n P_i \quad (6)$$

将式(5)、(6)代入式(3),有

$$\hat{Y} = \frac{S_N}{S_D} \quad (7)$$

上述 GRNN 模型由 4 层网络构成,依次为输入层、模式层、求和层和输出层(见图 1)。

其中,输入层接收学习样本,其神经元数等于样本向量的维数;模式层接收输入层传递的信息并将其经式(4)转换后传递至求和层;求和层中有 2 类神经元,分别对模式层中数据通过式(5)、(6)进行求和;输出层最终计算结果为式(7)。




图 1 广义回归神经网络结构图

Fig.1 GRNN block diagram

GRNN 模型结构简单，只需一个参数，即光滑因子  $\sigma$ ，因此最大限度的减少了模型参数选择的人为因素影响，降低了网络结构设计的随意性。目前， $\sigma$  的选取主要采用手工调整方法，存在效率低、精度差的问题。从数学上讲， $\sigma$  的确定实质上是一个优化问题，即通过寻找一个最优的  $\sigma$ ，使得训练样本的 GRNN 输出值与实际值的均方差最小。本文采用粒子群算法对 GRNN 模型进行优化，并通过 Matlab 程序实现。

## 2.2 基于粒子群算法的 GRNN 模型优化

粒子群算法是一种模拟鸟类相互协作寻找食物的智能算法<sup>[15]</sup>。目标优化问题  $M$  的解为  $d$  维向量，其解的优劣以适应度  $F$  为标准进行评价。假定其最优解为  $L_{best}$ ，将  $L_{best}$  看做  $d$  维空间中的一个粒子，其位置为  $(l_{b1}, l_{b2}, l_{b3}, \dots, l_{bd})$ 。采用粒子群算法寻找  $L_{best}$ ：假定在  $d$  维空间中随机散布  $n$  个粒子，其位置为  $L_i = (l_{i1}, l_{i2}, l_{i3}, \dots, l_{id}) (i = 1, 2, 3, \dots, n)$ ，将  $L_i$  代入函数  $M(L)$  并计算其适应度值  $F_i$ 。根据适应度值确定第  $i$  个粒子在运动过程中所经历过的最优位置  $P_{bi} = (p_{i1}, p_{i2}, p_{i3}, \dots, p_{id})$ 、群体所有粒子经历过的最优位置  $G_b = (p_{g1}, p_{g2}, p_{g3}, \dots, p_{gd})$ 。各个粒子根据其当前所处的位置  $L_i$ 、其自身所发现的最优位置  $P_{bi}$  以及群体所发现的最优位置  $G_b$  可按下式调整，寻找  $L_{best}$ ：

$$v_{id}^{(k+1)} = uv_{id}^{(k)} + c_1 r_1 (p_{id}^{(k)} - l_{id}^{(k)}) + c_2 r_2 (p_{gd}^{(k)} - l_{id}^{(k)}) \quad (8)$$

$$l_{id}^{(k+1)} = l_{id}^{(k)} + v_{id}^{(k+1)} \quad (9)$$

式中： $u$  为惯性因子； $v_{id}^{(k)}$  为第  $k$  次迭代中粒子  $i$  的速度向量的第  $d$  维分量； $c_1, c_2$  均为学习因子； $r_1, r_2$  均为  $(0, 1)$  区间的随机数。式(8)右端第一项为粒子的初始速度，第二项反映了粒子自身的“记忆”与“进化”功能，第三项反映了种群内粒子间的相互“学习”能力。模型达到迭代终止条件后以全局中最优位置处粒子  $G_b$  作为目标问题的最优解。

对于 GRNN 模型，以训练样本的输出值与实际值的均方差作为适应度函数寻找最优  $\sigma$ ，PSO 优化 GRNN 过程及 Matlab 伪代码如下：

※(1) 设置粒子群计算参数；

```
sizepop = s;           %种群规模
c1 = a;                 %记忆因子
c2 = b;                 %进化因子
popmax = p1;           %粒子最大值
popmin = p2;           %粒子最小值
Vmax = v1;              %粒子最大速度
Vmin = v2;              %粒子最小速度
pop(i, :) = P*rands(a, b); %随机设置粒子位置
V(i, :) = rands(c, d);  %随机设置粒子速度
```

※(2) 设置适应度函数；

```
fitness(i) = fun(pop(i, :)); %适应度设置
```

※(3) 将学习样本和粒子代入 GRNN，计算适应度值  $F_i$ ；

```
net1 = newgrnn(A, B, x)
y = (g^0.5)/N
```

※(4) 比较第  $i$  个粒子所经过的所有位置的适应度值，确定其最优位置  $P_{bi}$ ；

```
if fitness(j) < fitnessgbest(j)
    gbest(j, :) = pop(j, :);
    fitnessgbest(j) = fitness(j);
end
```

※(5) 比较所有粒子在其最优位置  $P_{bi}$  的适应度值，确定整个种群的最优位置  $G_b$ ；

```
if fitness(j) < fitnesszbest
    zbest = pop(j, :);
    fitnesszbest = fitness(j);
end
```

※(6) 根据各粒子自身位置及最优粒子位置调整粒子的速度和位置；

```
V(j, :) = V(j, :) + c1*rand*(gbest(j, :) - pop(j, :)) + c2*rand*
(zbest - pop(j, :));
pop(j, :) = pop(j, :) + 0.5*V(j, :);
```

※(7) 达到迭代终止条件，采用搜索到的最佳  $G_b$  构建 GRNN。

```
zbest = fitnesszbest %最优粒子
net = newgrnn(P, T, zbest) %最优 GRNN
```

基于 PSO 算法和 GRNN 模型的岩爆预测流程图见图 2。

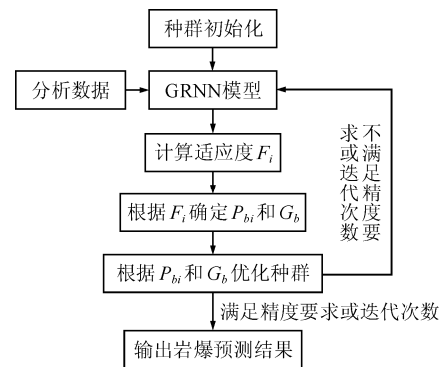


图 2 基于粒子群算法和广义回归神经网络模型的岩爆预测流程图

Fig.2 Flow chart of rockburst prediction using PSO algorithm and GRNN model

3 基于 PSO-GRNN 模型的岩爆预测

3.1 PSO-GRNN 岩爆预测模型

岩爆发生机制复杂, 影响因素众多, 主要包括岩性、围岩初始应力状态、隧道断面型式、开挖方法等。能量理论认为当岩体-围岩系统在其力学平衡状态破坏时, 如果释放的能量大于消耗的能量, 就会发生岩爆。基于该理论, 选取洞壁围岩最大切向应力 $\sigma_\theta$ 、岩石单轴抗压强度 $\sigma_c$ 、抗拉强度 $\sigma_t$ 、弹性能量指数 $W_{et}$ 四项指标作为神经网络的输入向量建立岩爆预测的回归分析模型, 其中洞壁围岩最大切向应力反映岩体所处应力水平, 单轴抗压、抗拉强度反映岩体的力学特性, 三者共同反映了岩体的力学平衡状态, 弹性能量指数反映了岩石储能状况, 综合 4 项指标可反映岩体力学平衡状态及岩体开挖时能量释放大小。

将岩爆分为 4 级, 即: 无岩爆(I 级)、轻微岩爆(II 级)、中等岩爆(III 级)和强烈岩爆(IV 级)。考虑 PSO-GRNN 模型的输入输出均为数值, 故对上述岩爆等级进行量化处理: 将各级岩爆按照均匀分布原则在[0, 1]间划分区间, 即以 0.00~0.25 表示无岩爆, 0.25~0.50 表示轻微岩爆, 0.50~0.75 表示中等岩爆, 0.75~1.00 表示强烈岩爆。

采用葛启发和冯夏庭<sup>[9]</sup>研究中的 26 组工程实例数据作为训练样本(见表 1)对 PSO-GRNN 模型进行训练, 模型训练过程中将学习样本分为 2 组进行交叉验证。

3.2 模型验证及工程应用

为验证 PSO-GRNN 岩爆预测模型的准确性和适用性, 采用上述模型分别对苍岭隧道和冬瓜山铜矿进行岩爆预测。

3.2.1 苍岭隧道岩爆预测

苍岭隧道位于浙江省境内括苍山山区, 最大埋深为 768 m, 主要穿越微风化凝灰岩和钾长花岗斑岩, 局部穿越断裂带和岩相接触带, 远离断层地段岩体较完整, 岩石单轴抗压强度 160 MPa, 地应力测试及反演结果显示隧道所处工程区最大主应力为

表 1 PSO-GRNN 岩爆预测模型学习样本

Table 1 Training samples for constructing PSO-GRNN model of rockburst prediction

分组	编号	$\sigma_\theta$ /MPa	$\sigma_c$ /MPa	$\sigma_t$ /MPa	$W_{et}$	岩爆等级	对应数值
第一组	1	48.8	180	8.3	5.0	III	0.625
	2	75.0	180	8.3	5.0	III	0.625
	3	62.5	175	7.3	5.0	III	0.625
	4	50.0	130	6.0	5.0	III	0.625
	5	80.0	180	6.7	5.5	II	0.375
	6	57.0	180	8.3	5.0	III	0.625
	7	60.0	200	9.8	5.0	II	0.375
	8	89.0	236	8.3	5.0	IV	0.875
	9	108.4	140	8.0	5.5	IV	0.875
	10	90.0	220	7.4	7.3	II	0.375
	11	30.0	89	3.7	6.6	III	0.625
	12	18.8	179	5.7	7.4	I	0.125
	13	90.0	170	11.3	9.0	III	0.625
第二组	14	62.6	165	9.4	9.0	II	0.375
	15	11.0	115	5.0	5.7	I	0.125
	16	43.4	123	6.0	5.0	II	0.375
	17	55.4	176	7.3	9.3	III	0.625
	18	98.6	120	6.8	3.8	III	0.625
	19	34.0	150	5.4	7.8	I	0.125
	20	48.0	120	1.5	5.8	III	0.625
	21	49.5	110	1.5	5.7	III	0.625
	22	63.0	115	1.5	5.7	III	0.625
	23	56.1	130	9.3	7.4	III	0.625
	24	60.7	112	7.9	6.2	IV	0.875
	25	54.2	136	9.2	7.1	III	0.625
	26	70.3	128	8.7	6.4	III	0.625

注:  $\sigma_\theta$  为洞壁围岩最大切向应力,  $\sigma_c$  为岩石单轴抗压强度,  $\sigma_t$  为抗拉强度,  $W_{et}$  为弹性能量指数, 下同。

17.9~27.3 MPa, 存在发生岩爆的可能。选取苍岭隧道 K97+702~K98+080, K98+225~K98+425, K98+637~K99+638, K99+638~K100+127 段进行岩爆预测, 分析数据见表 2。

表 2 苍岭隧道岩爆分析数据

Table 2 Data for rockburst analysis of Cangling tunnel

隧道路段	$\sigma_\theta$ /MPa	$\sigma_c$ /MPa	$\sigma_t$ /MPa	$W_{et}$
K97+702~K98+080	32.8	160	6.6	4.6
K98+225~K98+425	44.8	160	6.8	4.9
K98+637~K99+638	50.9	160	7.5	5.3
K99+638~K100+127	44.8	160	6.7	4.8

为检验粒子群参数对 PSO-GRNN 模型预测结果的影响, 分别建立 9 组粒子群参数不同的预测模型对苍岭隧道进行预测, 各模型预测结果见表 3。

表 3 苍岭隧道 PSO-GRNN 岩爆预测结果

Table 3 Rockburst prediction results of Cangling tunnel using generated PSO-GRNN model

隧道路段	预测结果									极差	本文方法	实际情况
	$c_1 = c_2 = 1.5$			$c_1 = c_2 = 2.0$			$c_1 = c_2 = 2.5$					
	$k = 100$	$k = 200$	$k = 300$	$k = 100$	$k = 200$	$k = 300$	$k = 100$	$k = 200$	$k = 300$			
K97+702~K98+080	0.366 3	0.375 8	0.376 7	0.379 9	0.380 4	0.386 2	0.378 4	0.384 0	0.373 4	0.019 9	II	II
K98+225~K98+425	0.479 6	0.482 1	0.482 3	0.483 1	0.483 3	0.484 7	0.482 7	0.484 2	0.482 7	0.005 1	II	II
K98+637~K99+638	0.512 8	0.513 6	0.513 7	0.513 9	0.514 0	0.514 4	0.513 8	0.514 2	0.513 8	0.001 6	III	III
K99+638~K100+127	0.479 6	0.482 1	0.482 3	0.483 1	0.483 3	0.484 7	0.482 7	0.484 2	0.482 7	0.005 1	II	II

注:  $k$  表示迭代次数;  $c_1, c_2$  均为学习因子, 见式(8)。

由表 3 中的结果可见，苍岭隧道各路段的预测结果均能正确反映岩爆的实际等级，显示了较好的精度。4 个路段预测结果的极差分别为 0.019 9，0.005 1，0.001 6，0.005 1，分别为相应判别区间长度的 8.0%，2.0%，0.6%，2.0%，说明该模型的初始参数  $c_1$ ， $c_2$  对结果影响很小，模型具有较好的稳定性。

3.2.2 冬瓜山铜矿岩爆预测

冬瓜山铜矿属于典型的深井硬岩矿山，矿体赋存标高大多在-730 m 以下，最大主应力为 30~38 MPa，方向与矿体走向大致相同，岩体坚硬、完整，矿体开采过程中存在发生岩爆的风险。本文对冬瓜山深埋矽卡岩进行岩爆预测，分析数据见表 4<sup>[6]</sup>。

表 4 冬瓜山铜矿岩爆分析数据<sup>[6]</sup>

Table 4 Data for rockburst analysis of Dongguashan copper mine<sup>[6]</sup>

岩性	$\sigma_0$ /MPa	$\sigma_c$ /MPa	$\sigma_1$ /MPa	$W_a$
矽卡岩	105.5	190.3	17.1	4.0

同样建立 9 组粒子群参数不同的 PSO-GRNN 预测模型，各模型预测结果见表 5。

由表 5 中的结果可见，PSO-GRNN 模型对冬瓜山铜矿矽卡岩岩爆预测结果与实际岩爆等级相同，显示了较好的精度。预测结果的极差为 0.001 0，为判别区间长度的 0.40%，说明 PSO-GRNN 模型具有较好的稳定性。

上述 2 个实例的结果一致，表明在一定量已有岩爆数据基础上构建的 PSO-GRNN 模型预测岩爆结果准确、稳定，对算法参数不敏感，降低了人为因素对预测结果的干扰，具有良好的工程适用性。

3.3 PSO-GRNN 模型与其他模型对比

进一步比较 PSO-GRNN 模型与普通 BP 神经网络模型和普通 GRNN 模型的优劣，采用表 1 中数据作为训练样本分别建立普通 BP 模型和普通 GRNN 模型对苍岭隧道和冬瓜山铜矿岩爆进行预测。

首先考察普通 BP 模型。模型迭代次数取 1 000，训练目标设置为 0.001，通过设置不同的隐含层节点数  $m$  和不同的学习速率考察 BP 模型预测结果的准确性和稳定性，模型预测结果见表 6。

由表 6 中的结果可见，与 PSO-GRNN 模型相比，BP 模型的预测结果对模型参数的变化比较敏感，预测结果不稳定，准确性较差。经过模型参数的调整优化，BP 模型预测的准确性可适当的提高，但由于 BP 模型参数较多，对其进行调整比较困难，人为因素的影响较大。

继续考察普通 GRNN 模型预测效果，在 1~50 范围内随机选取 10 个随机数( $r_1 \sim r_{10}$ )作为  $\sigma$  构建 10 组普通的 GRNN 模型，预测结果见表 7。

由表 7 中的结果可见，与 PSO-GRNN 模型相比，普通 GRNN 模型的预测结果不稳定，无法对岩爆进

表 5 冬瓜山铜矿 PSO-GRNN 岩爆预测结果

Table 5 Rockburst prediction results of Dongguashan copper mine using generated PSO-GRNN model

岩性	预测结果									极差	岩爆等级	
	$c_1 = c_2 = 1.5$			$c_1 = c_2 = 2.0$			$c_1 = c_2 = 2.5$				本文方法	实际情况
	$k = 100$	$k = 200$	$k = 300$	$k = 100$	$k = 200$	$k = 300$	$k = 100$	$k = 200$	$k = 300$			
矽卡岩	0.524 6	0.524 9	0.525 0	0.525 2	0.525 2	0.525 6	0.525 1	0.525 5	0.525 1	0.001 0	III	III

表 6 BP 岩爆预测结果

Table 6 Rockburst prediction results using BP neural network model

预测区段		预测结果(学习率取 0.1)									
		$m = 10$	$m = 20$	$m = 30$	$m = 40$	$m = 50$	$m = 60$	$m = 70$	$m = 80$	$m = 90$	$m = 100$
苍岭隧道	K97+702~K98+080	0.170 0	0.119 7	0.710 4	0.563 9	0.477 4	0.760 6	0.013 2	0.678 4	*-0.306 3	0.172 4
	K98+225~K98+425	0.572 0	0.457 9	0.726 6	0.541 1	0.559 4	0.859 2	0.433 3	0.299 5	0.442 7	0.329 3
	K98+637~K99+638	0.705 2	0.483 7	0.682 1	0.535 1	0.508 5	0.845 8	0.864 8	0.393 0	0.770 0	0.315 5
	K99+638~K100+127	0.534 0	0.458 8	0.730 8	0.543 3	0.603 4	0.837 8	0.369 6	0.276 2	0.439 2	0.418 5
冬瓜山铜矿矽卡岩		0.337 2	*1.332 3	0.686 4	0.179 0	*1.375 1	0.381 7	0.691 9	*1.176 3	*1.390 0	*-0.790 5
预测区段		预测结果(学习率取 0.2)									
		$m = 10$	$m = 20$	$m = 30$	$m = 40$	$m = 50$	$m = 60$	$m = 70$	$m = 80$	$m = 90$	$m = 100$
苍岭隧道	K97+702~K98+080	0.793 8	0.421 6	*1.082 3	0.374 0	0.006 3	*-0.599 4	*1.223 8	0.833 8	0.628 8	0.924 2
	K98+225~K98+425	0.705 8	0.711 5	0.890 3	0.458 4	0.092 0	0.161 4	0.897 3	0.816 6	*1.149 6	0.632 7
	K98+637~K99+638	0.624 5	0.837 8	0.697 8	0.519 3	0.439 2	0.633 9	0.644 6	0.604 0	*1.155 5	0.303 2
	K99+638~K100+127	0.743 7	0.684 2	0.934 9	0.463 6	0.058 0	0.064 9	0.929 0	0.855 9	*1.118 2	0.704 3
冬瓜山铜矿矽卡岩		0.421 3	0.805 2	0.292 9	0.152 5	*1.073 7	0.739 5	*-0.274 0	*1.954 9	*1.156 3	*2.499 3

注：表中带\*数据表示预测结果超出预测范围。

表 7 GRNN 岩爆预测结果  
Table 7 Rockburst prediction results using GRNN model

预测区段		预测结果									
		r1	r2	r3	r4	r5	r6	r7	r8	r9	r10
苍岭隧道	K97+702~K98+080	0.132 3	0.163 7	0.125 1	0.331 2	0.383 1	0.453 4	0.488 7	0.468 6	0.505 6	0.178 7
	K98+225~K98+425	0.325 7	0.391 4	0.204 6	0.470 2	0.483 9	0.502 8	0.515 4	0.507 7	0.523 2	0.405 3
	K98+637~K99+638	0.464 7	0.484 6	0.421 2	0.509 8	0.514 2	0.520 6	0.526 7	0.522 8	0.531 2	0.488 9
	K99+638~K100+127	0.325 4	0.391 3	0.204 0	0.470 2	0.483 9	0.502 8	0.515 4	0.507 7	0.523 2	0.405 2
冬瓜山铜矿矽卡岩		0.571 5	0.550 5	0.605 1	0.524 9	0.525 4	0.541 6	0.559 1	0.548 9	0.564 7	0.545 7

行准确预测, 经过粒子群算法优化的 GRNN 模型可显著提高预测结果的稳定性和准确性。

与其他智能方法相比, PSO-GRNN 模型最大的优势在于能够通过简单编码达到较高的预测精度和稳定性。

4 结 论

(1) 采用粒子群算法对广义回归神经网络设计参数进行优化, 解决了神经网络设计参数选取的随意性, 减少了人为因素对预测结果的影响。

(2) 基于能量理论, 选取洞壁围岩最大切向应力  $\sigma_{\theta}$ 、岩石单轴抗压强度  $\sigma_c$ 、抗拉强度  $\sigma_t$  和弹性能量指数  $W_{et}$  作为神经网络的输入向量, 综合反映了岩爆发生所需的力学条件和能量条件, 以此为基础建立的 PSO-GRNN 岩爆预测模型具有算法简单、适用型较好的特点。

(3) 苍岭隧道和冬瓜山铜矿岩爆预测实例分析结果表明, PSO-GRNN 预测结果与岩爆发生的实际情况一致, 并且预测结果稳定, 受粒子群算法参数影响小。对比分析显示 PSO-GRNN 模型在预测精度和稳定性上优于普通 BP 模型和 GRNN 模型, 为类似工程岩爆预测提供了一个新的方法。

参考文献(References):

[1] 张镜剑, 傅冰骏. 岩爆及其判据和防治[J]. 岩石力学与工程学报, 2008, 27(10): 2 034 - 2 042.(ZHANG Jingjian, FU Bingjun. Rockburst and its criteria and control[J]. Chinese Journal of Rock Mechanics and Engineering, 2008, 27(10): 2 034 - 2 042.(in Chinese))

[2] 吕 庆, 孙红月, 尚岳全, 等. 深埋特长公路隧道岩爆预测综合研究[J]. 岩石力学与工程学报, 2005, 24(16): 2 982 - 2 988.(LU Qing, SUN Hongyue, SHANG Yuequan, et al. Comprehensive study on prediction of rockburst in deep and over-length highway tunnel[J]. Chinese Journal of Rock Mechanics and Engineering, 2005, 24(16): 2 982 - 2 988.(in Chinese))

[3] 王元汉, 李卧东, 李启光, 等. 岩爆预测的模糊数学综合评判方法[J]. 岩石力学与工程学报, 1998, 17(5): 493 - 501.(WANG Yuanhan, LI Wodong, LI Qiguang, et al. Method of fuzzy comprehensive evaluations for rockburst prediction[J]. Chinese Journal of Rock Mechanics and Engineering, 1998, 17(5): 493 - 501.(in Chinese))

[4] 刘 春, 易 俊, 姜德义, 等. 基于灰色关联分析理论的岩爆烈度预测研究[J]. 中国矿业, 2007, 16(12): 100 - 103.(LIU Chun, YI Jun,

JIANG Deyi, et al. Study on rockburst intensity prediction method based on gray relational analysis theory[J]. China Mining Magazine, 2007, 16(12): 100 - 103.(in Chinese))

[5] 陈海军, 酆能惠, 聂德新, 等. 岩爆预测的人工神经网络模型[J]. 岩土工程学报, 2002, 24(2): 229 - 232.(CHEN Haijun, LI Nenghui, NIE Dexin, et al. A model for prediction of rockburst by artificial neural network[J]. Chinese Journal of Geotechnical Engineering, 2002, 24(2): 229 - 232.(in Chinese))

[6] 宫凤强, 李夕兵. 岩爆发生和烈度分级预测的距离判别方法及应用[J]. 岩石力学与工程学报, 2007, 26(5): 1 012 - 1 018.(GONG Fengqiang, LI Xibing. A distance discriminant analysis method for prediction of possibility and classification of rockburst and its application[J]. Chinese Journal of Rock Mechanics and Engineering, 2007, 26(5): 1 012 - 1 018.(in Chinese))

[7] 祝云华, 刘新荣, 周军平. 基于 v-SVR 算法的岩爆预测分析[J]. 煤炭学报, 2008, 33(3): 277 - 281.(ZHU Yunhua, LIU Xinrong, ZHOU Junping. Rockburst prediction analysis based on v-SVR algorithm[J]. Journal of China Coal Society, 2008, 33(3): 277 - 281.(in Chinese))

[8] 王迎超, 尚岳全, 孙红月, 等. 基于功效系数法的岩爆烈度分级预测研究[J]. 岩土力学, 2010, 31(2): 529 - 534.(WANG Yingchao, SHANG Yuequan, SUN Hongyue, et al. Study of prediction of rockburst intensity based on efficacy coefficient method[J]. Rock and Soil Mechanics, 2010, 31(2): 529 - 534.(in Chinese))

[9] 葛启发, 冯夏庭. 基于 AdaBoost 组合学习方法的岩爆分类预测研究[J]. 岩土力学, 2008, 29(4): 943 - 948.(GE Qifa, FENG Xiating. Classification and prediction of rockburst using AdaBoost combination learning method[J]. Rock and Soil Mechanics, 2008, 29(4): 943 - 948.(in Chinese))

[10] SPECHT D F. A general regression neural network[J]. Neural Networks, IEEE Transactions on, 1991, 2(6): 568 - 576.

[11] 周建萍, 闫焄旺. 广义回归神经网络预测加筋土挡墙结构高度[J]. 岩土力学, 2002, 23(4): 486 - 490.(ZHOU Jianping, YAN Shuwang. Generalized regression neural networks for predicting design height of GRW[J]. Rock and Soil Mechanics, 2002, 23(4): 486 - 490.(in Chinese))

[12] 余跃心, 刘汉龙, 高玉峰. 计算相关距离的神经网络方法[J]. 岩土力学, 2003, 24(5): 719 - 722.(SHE Yuexin, LIU Hanlong, GAO Yufeng. Neural networks method for computation of autocovariance distance[J]. Rock and Soil Mechanics, 2003, 24(5): 719 - 722.(in Chinese))

[13] 余跃心. 用神经网络残余 Kriging 预测场地液化势[J]. 成都理工大学学报: 自然科学版, 2005, 32(4): 368 - 372.(SHE Yuexin. Prediction of site liquefaction potential by the neural network residual Kriging[J]. Journal of Chengdu University of Technology: Science and Technology, 2005, 32(4): 368 - 372.(in Chinese))

[14] 刘开云, 乔春生, 刘保国. 基于遗传 - 广义回归神经元算法的玛石隧道三维弹塑性位移反分析研究[J]. 岩土力学, 2009, 30(6): 1 805 - 1 809.(LIU Kaiyun, QIAO Chunsheng, LIU Baoguo. Research on elastoplastic displacement back analysis method based on GA-GRNN algorithm in three-dimension of Wushi tunnel[J]. Rock and Soil Mechanics, 2009, 30(6): 1 805 - 1 809.(in Chinese))

[15] KENNEDY J, EBERHART R. Particle swarm optimization[C]// Proceedings of IEEE International Conference on Neural Networks. Perth, Australia: [s. n.], 1995: 1 942 - 1 948.